

Relações lineares e não-lineares na predição de parâmetros de Hubbard em estruturas metálicas-orgânicas

Pamela Costa Carvalho^{1*}; Walter Mesquita Filho²

¹ Universidade de Uppsala. Pós-doutoranda no departamento de Teoria de Materiais. Von Kraemers allé 29 – Kåbo; 752-37 Uppsala, Suécia

² Pecege. Professor Orientador. Parque Tecnológico R. Cezira Giovanoni Moretti, 600 - Santa Rosa; 13418-445 Piracicaba, São Paulo, Brasil

*autor correspondente: pamelacosta.res@gmail.com

Relações lineares e não-lineares na predição de parâmetros de Hubbard em estruturas metálicas-orgânicas

Resumo

No contexto da Física Computacional de Materiais, os parâmetros de Hubbard U e V , descrevem as correlações eletrônicas intra-sítio e inter-sítio em materiais, sendo importantes para corrigir a estrutura eletrônica de cálculos de primeiros princípios. No entanto, seu cálculo autoconsistente é computacionalmente custoso, especialmente para estruturas metálicas-orgânicas (MOFs), que possuem muitos átomos por célula unitária. Neste trabalho, investigou-se a predição de U e V em MOFs a partir do banco de dados TBHubbard, utilizando variáveis estruturais e de identidade química como descritores. Análise exploratória dos dados, tratamento de outliers e verificação de multicolinearidade foram realizados, seguidos do ajuste de modelos de regressão linear múltipla com seleção stepwise para U e V , e de Floresta Aleatória para V . O modelo linear para U apresentou uma ótima performance na base de teste ($R^2 = 0.970$, $MAE = 0.181$ eV), destacando a identidade química do átomo como principal determinante. Para V , o modelo linear mostrou-se inadequado, enquanto a Floresta Aleatória capturou satisfatoriamente a natureza não-linear da interação ($R^2 = 0.782$, $MAE = 0.050$ eV), com a distância entre sítios emergindo como variável de importância física relevante. Os resultados demonstraram que a identidade química dos átomos e variáveis geométricas locais, extraídas diretamente de geometrias cristalinas, foram suficientes para estimar os parâmetros de Hubbard sem cálculos eletrônicos prévios, oferecendo uma alternativa computacionalmente eficiente para a triagem de MOFs em larga escala.

Palavras-chave: aprendizado de máquina; regressão linear; DFT+U+V; floresta aleatória.

Linear and non-linear relationships in the prediction of Hubbard parameters in metal-organic frameworks

Abstract

In the context of Computational Materials Physics, the Hubbard parameters U and V describe the intra-site and inter-site electronic correlations in materials, being important for correcting the electronic structure of first-principles calculations. However, their self-consistent calculation is computationally expensive, especially for metal-organic frameworks (MOFs), which contain many atoms per unit cell. In this work, the prediction of U and V in MOFs was investigated using the TBHubbard database, with structural variables and chemical identity as predictors. Exploratory analysis, outlier treatment and multicollinearity verification were performed, followed by the fitting of multiple linear regression models with stepwise selection for U and V , and a Random Forest model for V . The linear model for U showed excellent performance on the test set ($R^2 = 0.970$, $MAE = 0.181$ eV), highlighting chemical identity as the main determinant. For V , the linear model was inadequate, while the Random Forest satisfactorily captured the non-linear nature of the interaction ($R^2 = 0.782$, $MAE = 0.050$ eV), with the inter-site distance emerging as a physically relevant variable. The results demonstrated that atomic chemical identity and local geometric variables, extracted directly from crystal geometries, were sufficient to estimate Hubbard parameters without prior electronic calculations, offering a computationally efficient alternative for large-scale screening of MOFs.

Keywords: machine learning; linear regression; DFT+U+V; random forest.

Introdução

Estruturas metálicas-orgânicas, ou “metal-organic frameworks” [MOFs], são materiais porosos e promissores devido a sua alta diversidade de aplicações, como captura e

armazenamento de gases (Zhao *et al.*, 2024), catálise (Bavykina *et al.*, 2020), transporte e difusão (Wu *et al.*, 2023). Tais estruturas são formadas por blocos estruturais, onde clusters metálicos se conectam a ligantes orgânicos, estabelecendo uma estrutura cristalina com muitos espaços vazios, chamados poros. Em função da vasta possibilidade de combinações desses blocos estruturais, os MOFs apresentam enorme diversidade em sua composição, o que permite o ajuste de propriedades com potencial para o design de novos materiais (Mancuso *et al.*, 2020). Nesse contexto, a simulação computacional de materiais se apresenta como ferramenta fundamental para explorar e intensificar a descoberta de compostos com propriedades otimizadas. Cálculos de primeiros princípios, baseados na Teoria do Funcional da Densidade (Hohenberg; Kohn, 1964; Kohn; Sham, 1965), ou “Density Functional Theory” [DFT], são exemplos de metodologia empregada para investigar aspectos eletrônicos de moléculas, sólidos e em particular, de MOFs.

A descrição de MOFs através de Hamiltonianas de rede pode ser muito útil por prover informações não só estruturais como também eletrônicas. Nesse contexto, a Hamiltoniana de Hubbard Estendida (Leiria Campo Jr; Cococcioni, 2010), ou modelo Estendido de Hubbard [EH], é capaz também de contabilizar as fortes correlações eletrônicas por meio dos parâmetros Hubbard intra-sítio e inter-sítio U e V , respectivamente. Normalmente, U está associado ao site do metal de transição, devido a seus orbitais atômicos localizados, e V representa a conexão entre o metal e seus sítios vizinhos mais próximos. Além disso, outra aplicação do modelo EH em cálculos de primeiros princípios é introduzir correções para tratar adequadamente os orbitais d e f , conhecidas como DFT+ U ou DFT+ U + V , melhorando a precisão da estimativa de “band gaps” (faixa de energia onde não existem estados eletrônicos), uma vez que a DFT usualmente falha na descrição de sistemas fortemente correlacionados (Pavarini, 2021). Como o cálculo de U e V a partir de primeiros princípios é excepcionalmente caro computacionalmente, a existência de banco de dados com valores de U e V computados para MOFs é uma contribuição valiosa, onde modelos de aprendizado de máquina, ou “machine learning” [ML], podem ser treinados para a predição de parâmetros Hubbard, economizando recursos e tempo.

Nesse contexto, o aprendizado de máquina tem se mostrado uma ferramenta promissora para a predição das propriedades eletrônicas de materiais a partir de descritores estruturais e químicos, sem a necessidade de cálculos de primeiros princípios. Abordagens supervisionadas, como regressão linear, florestas aleatórias e métodos de “boosting” por gradiente, têm sido aplicadas com sucesso na predição de propriedades de MOFs a partir de bases de dados computacionais (Rosen *et al.*, 2022, 2021). Em particular, a disponibilidade de bancos de dados de larga escala de MOFs, como o QMOF (Rosen *et al.*, 2021, 2022) e o TBHubbard (Costa Carvalho *et al.*, 2025; Costa Carvalho; Zipoli, 2025) abre caminho para o

treinamento de modelos preditivos capazes de estimar parâmetros de Hubbard diretamente a partir de variáveis acessíveis, como identidade química dos átomos, volume, densidade e cargas eletrônicas, eliminando o custo computacional associado ao cálculo autoconsistente de U e V para cada estrutura individualmente.

O objetivo deste trabalho foi investigar se variáveis estruturais e de identidade química são capazes de prever os parâmetros de Hubbard U e V em MOFs, identificando as relações lineares e não-lineares envolvidas.

Metodologia

Modelo EH

No contexto dos MOFs, pode-se pensar nos átomos como elementos que interagem entre si dentro de uma estrutura, de forma semelhante a uma rede de conexões. Aqui, para descrever essas interações, utilizou-se o modelo EH, onde os efeitos entre átomos foram representados por dois tipos principais de parâmetros. O primeiro tipo descreveu a interação local, ou seja, quando um átomo influenciou a si mesmo, sendo representado por U . O segundo tipo descreveu a interação entre átomos diferentes, sendo representado por V . De forma mais específica, considerou-se que cada átomo ocupou um sítio na estrutura. Quando dois sítios diferentes (i e j) interagem, utilizou-se o termo V_{ij} . Já no caso de U , o átomo interagiu consigo mesmo, ou seja, $i = j$. Usualmente, U é associado a metais de transição, mas também pôde ser calculado para a parte orgânica vizinha ao metal (geralmente átomos de O e N). Já V_{ij} (inter-sítio) representou a interação do metal com seus átomos vizinhos, não se restringindo aos vizinhos mais próximos, e, portanto, a distância entre os sítios i e j foi uma propriedade determinante para a interação. Quanto mais afastados os átomos, menor é V_{ij} . Na Figura 1, pode-se ver a ilustração de um MOF com a conexão do centro metálico (Pt) com a parte inorgânica (C e N). Logo, no TBHubbard, apesar do número de materiais disponíveis ser restrito (242), existem inúmeros valores de U e V para cada material, onde estes se associam a um ou dois elementos químicos, respectivamente.




Figura 1: Ilustração de parte de uma estrutura metálico-orgânica, com o centro metálico (átomo de Pt em cinza) conectado com a parte orgânica (átomo de C em marrom). O parâmetro U é associado ao metal (U_{Pt}), enquanto o V representa a interação entre o metal e os ligantes orgânicos (V_{Pt-C})

Fonte: Dados originais da pesquisa

Essas interações são inseridas no modelo EH através da hamiltoniana descrita na eq. 1 (Leiria Campo Jr; Cococcioni, 2010):

$$\mathcal{H} = -t \sum_{\langle i,j \rangle, \sigma} c_{i\sigma}^\dagger c_{j\sigma} + \frac{1}{2} \sum_i U_{ii} n_i n_i + \frac{1}{2} \sum_{\langle i,j \rangle} V_{ij} n_i n_j \quad (1)$$

em que $\hat{c}_{i\sigma}^\dagger$ é o operador de criação de elétrons no sítio i com spin σ , n_i é a densidade no sítio i e $\langle i,j \rangle$ denota que os sítios i e j são vizinhos próximos. Aqui, t é a amplitude de *hopping*, U é a interação local de Hubbard e V é a interação de Coulomb não-local. Logo, a correção da estrutura eletrônica pelo modelo EH pode ser feita através de métodos como DFT+U+V, a partir da disponibilidade dos parâmetros U e V .

Fonte dos dados e definição de variáveis

Neste trabalho, utilizou-se o banco de dados TBHubbard, associado ao banco de dados QMOF, para extrair as variáveis explicativas, onde foram extraídas propriedades estruturais e eletrônicas de caráter local para cada material, e as variáveis resposta U e V . A densidade (*density*) e o volume (*volume*) dos materiais foram exemplos de propriedades estruturais utilizadas. Além disso, como os MOFs são materiais porosos (com muitos espaços vazios dentro do cristal), o diâmetro limitante de poro (o maior diâmetro que uma molécula precisa ter para passar pelos poros, definido aqui como *pld*) e o diâmetro da maior cavidade (o maior espaço disponível dentro da estrutura, definido aqui como *lcd*) também foram utilizados. Conforme ilustrado na Figura 2, essas características estruturais (*pld*, *lcd*, *density* e *volume*) são propriedades globais da estrutura cristalina do material como um todo e, portanto, apresentam apenas um valor por material. Em contraste, as propriedades eletrônicas possuem natureza local e foram definidas para pares de sítios atômicos dentro de

cada estrutura. Nesse caso, o banco de dados foi organizado em termos de pares de átomos (i, j), onde cada observação descreve uma interação específica entre dois sítios atômicos. Assim, para cada par, foram consideradas informações como o nome de elemento químico presente no sítio i ($atom_i$) e no sítio j ($atom_j$), as cargas eletrônicas associadas a cada sítio ($ddec_charge_i$ e $ddec_charge_j$), e a distância entre os átomos ($distance$), conforme também indicado na Figura 2. Dessa forma, cada observação contém simultaneamente informação estrutural do material e informação eletrônica local associada à interação entre dois átomos.




Figura 2: Representação esquemática das variáveis explicativas extraídas do banco de dados TBHubbard/QMOF. À esquerda, são mostradas as propriedades estruturais globais do material, incluindo o diâmetro limitante de poro (pld), o diâmetro da maior cavidade (lcd), a densidade e o volume, as quais são únicas para cada estrutura cristalina. À direita, é apresentada a descrição das propriedades eletrônicas locais, definidas para pares de sítios atômicos (i, j), incluindo o tipo de elementos nos sítios i e j , as cargas eletrônicas locais ($ddec_charge_i$ e $ddec_charge_j$) e a distância inter-atômica ($distance$). Esses descritores são utilizados para caracterizar as interações U (intra-sítio, $i = j$) e V (inter-sítio, $i \neq j$) no modelo Estendido de Hubbard

Fonte: Dados originais da pesquisa

As variáveis estruturais corresponderam a propriedades únicas de cada material, enquanto as propriedades eletrônicas variaram para cada par de átomos de acordo com o ambiente no qual eles estiveram inseridos. Portanto, apesar do banco de dados conter apenas 242 MOFs, ao descrever as propriedades eletrônicas de forma local, i.e., o conjunto de dados resultante incluiu aproximadamente 460.000 observações, uma vez que cada MOF possui dezenas ou centenas de átomos. É interessante notar que a interação de Hubbard também pôde ser descrita como uma função universal $F_{ij}(i, j, R_{ij}, \dots)$ que dependeu dos elementos químicos nos sítios i e j , a distância entre eles (R_{ij}) e de outros fatores que se tentou inferir. Logo, para a interação U ($F_{i=i}$), teve-se que $R_{ij} = 0$, enquanto os outros casos se referiram à interação V ($F_{i \neq j}$).

Para a modelagem, consideraram-se como descritores as variáveis numéricas: *lcd*, *pld*, *density*, *volume*, *ddec_charge_i*, *ddec_charge_j* e *distance*, além das variáveis categóricas: *atom_i* e para as interações inter-sítio, *atom_j* (Tabela 1). O subconjunto com distância igual a zero foi utilizado para o parâmetro U (intra-sítio), onde as variáveis referentes ao átomo *j* e distância se tornaram redundantes e foram retiradas. O subconjunto com distância diferente de zero foi utilizado para o parâmetro V (inter-sítio), mantendo-se a variável *distance* e nome do elemento químico de ambos os átomos.

Tabela 1. Variáveis extraídas dos bancos de dados TBHubbard e QMOF, incluindo propriedades estruturais globais e descritores eletrônicos locais utilizados como descritores na modelagem das interações U (intra-sítio) e V (inter-sítio), com seus respectivos tipos, unidades e descrições.

Variável	Tipo	Unidade	Descrição	Caráter
<i>pld</i>	Numérica	Å	Diâmetro limitante do poro	Estrutural
<i>lcd</i>	Numérica	Å	Diâmetro da maior cavidade	Estrutural
<i>density</i>	Numérica	g/cm ³	Densidade de massa	Estrutural
<i>volume</i>	Numérica	cm ³	Volume do material	Estrutural
<i>ddec_charge_i</i>	Numérica	----	Carga eletrônica no sítio <i>i</i>	Local
<i>ddec_charge_j</i>	Numérica	----	Carga eletrônica no sítio <i>j</i>	Local
<i>atom_i</i>	Categórica	----	Nome do elemento no sítio <i>i</i>	Local
<i>atom_j</i>	Categórica	----	Nome do elemento no sítio <i>j</i>	Local
U/V	Numérica	eV	Interação U/V	Local
<i>distance</i>	Numérica	Å	Distância entre os sítios <i>i</i> e <i>j</i>	Local

Fonte: Dados originais da pesquisa

Pré-processamento dos dados

Após definir os subconjuntos de dados para U e V, realizou-se correção de inconsistências nos rótulos de elementos (por exemplo, variantes como O7 ou N6 foram mapeadas para O e N), além de verificar a existência de variáveis ausentes, removendo valores do tipo “Not a Number” [NaN]. O conjunto de dados foi dividido em treino e teste na proporção 80%–20%, com semente fixa para reprodutibilidade, de modo a avaliar o desempenho dos modelos em dados não utilizados no ajuste (James *et al.*, 2021). Note que a divisão foi feita por material e não por observação, para garantir que um mesmo material não esteja presente simultaneamente no treino e no teste, evitando assim o vazamento de informação. Após a visualização da distribuição dos dados por meio de gráficos do tipo *boxplot*, notou-se a presença de valores *outliers*, que podem decorrer de cálculos errôneos dos parâmetros U/V para elementos químicos, para os quais a metodologia de cálculo talvez

não seja adequada (Apêndice A). Para a remoção desses valores, utilizou-se o método da amplitude interquartílica (IQR), no qual observações fora do intervalo $[Q1 - 1,5 \times IQR; Q3 + 1,5 \times IQR]$ são consideradas atípicas e podem ser excluídas ou tratadas separadamente (Tukey, 1977). Aplicou-se o critério dentro de cada grupo: para U, cerca de 9% dos dados foram removidos, enquanto para o V cerca de 16% dos valores foram removidos (Tabela 2). Além disso, devido a natureza da interação V, que decai com a distância entre os sítios i e j , houve uma grande concentração de valores nulos ou desprezíveis para esse subconjunto. Para não inflar o modelo de forma desproporcional com interações nulas, escolheu-se o ponto de corte de 0.01 eV, onde observações com valores menores que esse foram desconsideradas. A escolha desse ponto de corte foi justificada através da precisão dos métodos computacionais para calcular tais interações. Neste segundo filtro para o subconjunto V, cerca de 40% dos dados foram removidos (Tabela 2). Importante notar que a remoção de dados baseados em *outliers* foi realizada após a divisão treino e teste para evitar o vazamento de informação da base treino para a base teste.

Tabela 2. Número final de observações nos dados de treino e teste para os subgrupos U e V, com o número de MOFs incluídos em cada caso

	U	V	Número de MOFs
Treino	7083	178924	193
Teste	1658	40927	49

Fonte: Dados originais da pesquisa

Para realizar a análise exploratória dos dados, utilizaram-se o coeficiente de correlação de Pearson e gráficos de dispersão para avaliar a relação entre as variáveis.

Análise de multicolinearidade

A partir dos fatores de correlação de Pearson, notou-se uma alta correlação no bloco de variáveis estruturais. Para evitar problemas de multicolinearidade na regressão linear, a inflação da variância [VIF] foi calculada na base de treino, que mede o aumento da variância dos estimadores dos coeficientes em relação à ausência de correlação entre os regressores; valores elevados podem indicar multicolinearidade problemática (Belsley et al. 1980). Aqui, adotamos um ponto de corte de $VIF > 5$ para indicar a presença de multicolinearidade (Hocking e Pendleton, 1983). A variável *lcd* apresentou VIF elevado (Tabela 3) e foi excluída das bases de treino e teste para ambos os casos U e V.

Tabela 3. Variável VIF para os descritores estruturais nos subgrupos U e V

	U	V
pld	2.31	2.58
lcd	6.10	6.73
volume	2.85	2.75
density	3.52	3.74

Fonte: Resultados originais da pesquisa

As variáveis categóricas de elemento foram codificadas por variáveis indicadoras (*one-hot encoding*), em que cada categoria é representada por uma variável binária e uma categoria de referência é omitida para evitar multicolinearidade perfeita, procedimento padrão em regressão e em aprendizado de máquina (Gujarati; N. Porter, 2011). Para U utilizou-se apenas *atom_i*; para V utilizou-se *atom_i* e *atom_j*. Após a aplicação do *one-hot encoding*, o subconjunto U possui 30 descritores, enquanto V possui 58.

Métricas para avaliação dos modelos

Neste trabalho, considerou-se y_i como o valor real, ou observações, da variável resposta (aqui, U ou V), $\hat{y}_i$ como o valor predito pelos modelos e $\bar{y}$ é a média do valor real. Seguindo estas nomenclaturas, a acurácia dos modelos foi avaliada por meio das seguintes métricas estatísticas na base de treino e teste (Fávero e Belfiore, 2024):

- Erro Médio Absoluto (MAE – Mean Absolute Error): o MAE calcula a magnitude do erro absoluto médio da amostra, na eq. 2:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2)$$

- Raiz do Erro Quadrático Médio (RMSE – Root Mean Squared Error): o RMSE calcula a raiz do erro quadrático médio, eq. 3:

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}} \quad (3)$$

- Coeficiente R^2 : determina o quanto da variação da variável resposta (aqui U ou V) é explicada pelas variáveis descritores, de acordo com a eq. 4:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (4)$$

No caso dessas duas métricas, neste trabalho foram consideradas as condições $RMSE \sim 0$ e $R^2 \sim 1$ como condições ideais, sendo que o melhor modelo foi o que mais se aproximou desse caso, conforme interpretação padrão de métricas de regressão (Gujarati e Porter, 2011; James et al., 2021)

Algoritmos de regressão

Foram empregadas duas abordagens principais para a predição dos parâmetros:

- **Regressão linear com seleção *stepwise*:** Ajustaram-se modelos de regressão linear múltipla, que estimam os coeficientes ($\hat{\beta}$) minimizando a soma dos quadrados dos resíduos. Sendo X a matriz com as variáveis descritoras, os coeficientes podem ser calculados pela eq. 5:

$$\hat{\beta} = (X^T X)^{-1} X^T y \quad (5)$$

Para seleção de variáveis, aplicou-se o procedimento *stepwise*, que utiliza o p-valor para a remoção de descritores que não são estatisticamente significativos (Kutner et al., 2004). Aqui, foi utilizado o intervalo de 95% de confiança e portanto, variáveis com $p \geq 0.05$ foram excluídas.

- **Floresta Aleatória:** Para o subconjunto V , foi ajustado o modelo não-linear de Floresta Aleatória (Random Forest) baseado na árvore de decisão para regressão. A árvore de decisão particiona o espaço dos descritores em regiões e atribui a cada região a média dos valores da variável resposta, minimizando a soma dos quadrados dos resíduos dentro dos nós (Breiman, L. et al., 1984). A Floresta Aleatória combina múltiplas árvores ajustadas em subamostras com subconjuntos aleatórios de descritores em cada divisão, reduzindo variância e “overfitting” (Breiman, Leo, 2001). Os hiperparâmetros foram selecionados por meio de busca em grade (*grid search*) com validação cruzada (Tabela 4), utilizando o método GridSearchCV, com três partições (*folds*) e métrica de otimização baseada na minimização do RMSE (James et al., 2021). A semente aleatória foi fixada em todas as etapas para garantir reprodutibilidade.

Tabela 4. Hiperparâmetros ajustados na Floresta Aleatória (continua)

Floresta Aleatória		Explicação
max_depth	5, 10	Profundidade máxima

Tabela 5. Hiperparâmetros ajustados na Floresta Aleatória (conclusão)

	Floresta Aleatória	Explicação
min_samples_split	20, 50	Número mínimo de amostras
min_samples_leaf	10, 30	Tamanho mínimo por folha
n_estimators	100, 300	Número de árvores
max_features	sqrt, 0.6	Fração de descritores por divisão

Fonte: Dados originais da pesquisa

Teste de normalidade dos resíduos

Para validar a aplicabilidade dos modelos de regressão linear e garantir a confiabilidade das inferências estatísticas (como os p-valores dos coeficientes), aplicou-se o teste de Shapiro-Francia sobre os resíduos do modelo. Diferente de outros testes de aderência, o Shapiro-Francia baseia-se na correlação entre os dados observados e os escores normais esperados (Shapiro; Francia, 1972). O teste avalia as seguintes hipóteses:

- Hipótese Nula (H_0): Os resíduos seguem uma distribuição normal.
- Hipótese Alternativa (H_1): Os resíduos não seguem uma distribuição normal.

A interpretação é realizada através do p-valor: caso o p-valor seja superior ao nível de significância adotado aqui (95% de confiança), não se rejeita H_0 , assumindo-se a normalidade dos resíduos.

Resultados e Discussão

Análise exploratória

Através dos coeficientes de correlação de Pearson, apresentados na Figura 3, nota-se uma alta correlação no sub-bloco estrutural entre as variáveis *pld*, *lcd*, *density* e *volume*. Como são variáveis de mesma natureza e referentes à estrutura do material, é esperado que elas estejam correlacionadas entre si. Entretanto, a variável resposta U/V não apresenta correlação significativa com este bloco. Enquanto U está correlacionado com a carga no sítio *i*, V está correlacionado com a distância entre os sítios *i* e *j*. Este é um resultado fisicamente esperado, já que a interação entre dois sítios decai com a distância. Logo, vemos que para ambos os subconjuntos de dados, as variáveis estruturais podem não ser relevantes para os modelos de regressão considerados aqui.




Figura 3. Matriz de correlação de Pearson entre as variáveis descritoras numéricas para os subconjuntos (a) U e (b) V. O mapa de cores representa a intensidade do coeficiente
Fonte: Resultados originais da pesquisa

Avaliando o comportamento de U/V como função das variáveis numéricas (de caráter estrutural e carga no sítio) nas Figuras 4 e 5, nota-se um certo agrupamento dos dados de acordo com o elemento químico, onde as variáveis estruturais não influenciam o valor da interação. Por exemplo, os átomos de O apresentam uma dispersão em torno da média de $U = 8$ eV, nas Figuras 4(a)-(e), quase de forma constante. O mesmo pode ser observado para os átomos de Zr e Hf que apresentam uma dispersão em torno da média de 3 eV. Este é um forte indicativo de que o elemento químico se configura como uma variável relevante para descrever o comportamento de U. A dispersão para a carga eletrônica no sítio i na Figura 4(e) pode indicar uma correlação com a variável resposta, dependendo do elemento químico, como já apontado pelo coeficiente de correlação de Pearson. Além disso, na Figura 4(f) apresenta-se o histograma da distribuição dos valores de U por elemento químico, no qual se observa a concentração de observações em elementos como O, Zr, N e Hf e a baixa frequência para diversos outros elementos, ilustrando a distribuição desigual que pode afetar a generalização dos modelos para tipos químicos pouco representados.




Figura 4. Gráfico de dispersão para o subconjunto U em função das variáveis numéricas (a) pld , (b) lcd , (c) $density$, (d) $volume$ e (e) $ddec_charge_i$. O histograma da distribuição de elementos químicos no banco de dados está apresentado em (f). O mapa de cores representa os elementos químicos que correspondem aos átomos no sítio i . Os dados referem-se à base TBHubbard

Fonte: Resultados originais da pesquisa

Para o subconjunto V , um comportamento similar a U é observado para as variáveis estruturais (Figura 5), onde o valor de V parece depender do elemento químico e ser menos correlacionado com as propriedades estruturais. Aqui é importante enfatizar que apesar de apenas o sítio i ser indicado, a interação V é sempre referente a um par de átomos nos sítios i e j . Devido à grande quantidade de dados para esta variável, escolheu-se apresentar os pontos em função apenas de um dos átomos da interação para facilitar a visualização. Nota-se que as interações com O dominam o conjunto de dados, consequência da alta concentração de O e nitrogênio (N) nas estruturas organometálicas. É interessante observar que para determinados valores de pld , $density$ e $volume$, os valores de V apresentam grande variação, se destacando dos outros casos. Isto pode indicar um comportamento atípico em um material específico ou em um grupo de materiais. Enquanto na variável carga eletrônica no sítio i nota-se um agrupamento dos pontos por elemento químico de forma mais evidente, existe uma clara correlação na dispersão dos dados de V em função da distância. Para interações que envolvem o elemento O, por exemplo, aparentemente há um decaimento exponencial de V em função da distância entre os sítios. Este é um forte indicativo de que um modelo linear talvez não seja adequado para a predição de V .




Figura 5. Gráfico de dispersão para o subconjunto V em função das variáveis numéricas (a) *pld*, (b) *lcd*, (c) *density*, (d) *volume*, (e) *ddec_charge_i* e (f) *distance*. O mapa de cores representa os elementos químicos correspondem aos sítios i. Os dados são referentes à base TBHubbard.

Fonte: Resultados originais da pesquisa

Regressão linear para prever U

Os resultados da regressão linear múltipla para o subconjunto U indicam que o modelo apresenta elevada capacidade explicativa global, evidenciada pela estatística $F = 8973$ A e seu respectivo p -valor = 0, com 30 graus de liberdade, permitindo afirmar que o conjunto das variáveis independentes contribui de forma significativa para a explicação da variável resposta U. Esse comportamento é consistente com o alto valor do R^2 (Tabela 5), indicando que o modelo captura a maior parte da variabilidade observada nos dados. Durante o procedimento *stepwise*, nenhuma variável foi removida, todas as quais apresentaram significância estatística, com p -valores menores que 0.05, estando dentro do intervalo de 95% de confiança. Além disso, a alta performance na base de teste indica que o modelo generaliza bem para dados novos, não havendo sinal de *overfitting*.

Tabela 5. Métricas R^2 , RMSE e MAE, analisadas na base de treino e teste, para o modelo de regressão linear para o subconjunto U

	Treino	Teste
R^2	0.974	0.970
RMSE	0.297	0.304
MAE	0.195	0.181

Fonte: Resultados originais da pesquisa

No painel de valores preditos versus valores reais (Figura 6), a boa aderência dos pontos à diagonal para a faixa intermediária de U (aproximadamente 4-9 eV) indica que o modelo captura razoavelmente bem o comportamento central dos dados. Tal fato está diretamente ligado ao alto R^2 na base de teste. Entretanto, para alguns elementos com valores elevados de U (acima de 9 eV), há um alto desvio, que é evidenciado na Figura 6(c), onde os resíduos estão plotados como função do valor predito de U. Aqui, destaca-se o Br e o Cu, sugerindo que o modelo não captura completamente a variabilidade de U para estes elementos. O agrupamento do elementos químicos presentes nas Figuras 6(a) e 6(c), reforça o argumento de que U é fortemente determinado pela identidade química do átomo, e variáveis estruturais possuem poder explicativo limitado para capturar essa variabilidade entre elementos, conforme já indicado pela análise de correlação de Pearson.




Figura 6. Modelo de regressão linear múltipla para o parâmetro U na amostra de teste. (a) Valores preditos versus os valores reais de U, onde a linha tracejada representa o ajuste perfeito; (b) Distribuição dos resíduos com a curva normal de referência sobreposta (linha tracejada vermelha); (c) Resíduos em função dos valores preditos; (d) Distribuição dos resíduos por elemento químico na forma de boxplot; (e) Coeficientes estimados pelo modelo após o procedimento stepwise, ordenados por magnitude. Os pontos coloridos em (a) e (c) estão de acordo com o elemento químico no sítio i
Fonte: Resultados originais da pesquisa

A distribuição dos resíduos apresenta forma aproximadamente normal, com leve deslocamento positivo da média e assimetria negativa, como pode ser visto na Figura 6(b). Esta cauda mais pronunciada negativa reflete a tendência do modelo em subestimar valores extremos de U para elementos como o Cu e Br, por exemplo (Figuras 6(c)-(d)). O teste de Shapiro-Francia indica desvio significativo da normalidade (estatística $W = 0.865$, $p = 0$), com

rejeição clara da hipótese nula, resultado consistente com a sensibilidade deste teste a grandes amostras, onde pequenos desvios podem ser tornar estatisticamente significativos (Hair *et al.*, 2019). Embora tal violação não comprometa necessariamente o poder preditivo do modelo, demonstrado pelo alto R^2 na base teste, ela pode impactar a validade de inferências para elementos químicos que não são bem representados na base de treinamento. Ou seja, o modelo linear funciona bem para elementos abundantes do banco de dados (O, Zr, Hf), mas subestima a predição de U para elementos mais raros (Cu, Br).

Analisando os coeficientes do modelo linear na Figura 6(e), observa-se que o intercepto domina a escala dos coeficientes, refletindo o caráter majoritariamente positivo e de magnitude moderada dos valores de U no banco de dados. Entre as variáveis de elemento, Cu apresenta o coeficiente positivo mais expressivo, enquanto os outros elementos apresentam coeficientes negativos. As variáveis estruturais e carga eletrônica apresentam coeficientes de menor magnitude, corroborando a hipótese de que a geometria dos materiais porosos contribuem de forma secundária para a predição de U em relação à identidade química no sítio.

Regressão linear para prever V

Diferentemente do observado para U, o modelo linear apresenta capacidade explicativa extremamente limitada para V (veja Tabela 6 e Figura 7). Apesar da estatística $F = 1704$ A e seu respectivo p-valor = 0, com 32 graus de liberdade, indicarem significância global do modelo, o R^2 de 0.234 na base de treino revela que 77% da variabilidade de V permanece inexplicada pelos descritores (Tabela 6). Na base de teste, o R^2 tem performance similar ao resultado da base de treino, indicando a ausência de *overfitting* significativo. É interessante notar que enquanto a MAE das bases de treino e teste são próximas, o RMSE é maior na base de treino, destacando a presença de valores *outliers*.

Tabela 6. Métricas R^2 , RMSE e MAE, analisadas na base de treino e teste, para o modelo de regressão linear para o subconjunto V

	Treino	Teste
R^2	0.234	0.167
RMSE	0.136	0.099
MAE	0.046	0.047

Fonte: Resultados originais da pesquisa

O procedimento *stepwise* removeu 26 variáveis com p-valor superior a 0.05, retraindo apenas 32 descritores no modelo final. Notavelmente, variáveis dummies de elementos

abundantes no banco de dados (Hf, C e O no sítio j) foram descartadas, o que sugere que a contribuição desses elementos para a interação V não segue um padrão linear. Esta observação pode ser fisicamente interpretável, já que enquanto U é determinado predominantemente pelo elemento químico, V depende da natureza do par atômico nos sítios i - j e da geometria de ligação, relações que escapam a formulações lineares simples. A falha do modelo linear em capturar essa relação fica visível no painel de valores preditos versus valores reais (Figura 7), onde existe uma dispersão pronunciada dos pontos em relação à diagonal e uma concentração das predições em torno de zero, independente do valor real de V .




Figura 7. Modelo de regressão linear múltipla para o parâmetro V na amostra de teste. (a) Valores preditos versus os valores reais de V , onde a linha tracejada representa o ajuste perfeito; (b) Distribuição dos resíduos com a curva normal de referência sobreposta (linha tracejada vermelha); (c) Resíduos em função dos valores preditos; (d) Distribuição dos resíduos por elemento químico na forma de *boxplot*; (e) Coeficientes estimados pelo modelo após o procedimento stepwise, ordenados por magnitude. Os pontos coloridos em (a) e (c) estão de acordo com o elemento químico no sítio i

Fonte: Resultados originais da pesquisa

Assim como para o subconjunto U , a distribuição dos resíduos na Figura 7(b) apresenta desvio da normalidade para o subconjunto V , evidenciado pelo teste de Shapiro-Francia ($W = 0.318$; $p = 0$). Entretanto, diferentemente de U , onde a violação de normalidade era atenuada pelo tamanho amostral e não comprometia o desempenho do modelo na base teste, aqui a magnitude do desvio reflete um maior afastamento da normalidade, corroborando a inadequação do modelo linear.

Os painéis de resíduos por valores preditos e elementos, apresentados nas Figuras 7(c)-(d), revelam resíduos majoritariamente positivos. De forma similar a U , a variação dos valores preditos pode variar com o elemento químico. Curiosamente, este comportamento não

está necessariamente correlacionado com a abundância do elemento químico, já que enquanto o modelo acerta para o Zr, a distribuição de resíduos para o N é bem mais dispersa, sendo que ambos os casos são elementos abundantes no banco de dados (Figura 7(d)). O agrupamento por elemento químico nas Figuras 7(a) e 7(c) sugere ainda que a identidade do par de átomos nos sítios i e j desempenha papel relevante na determinação de V , mas de forma que não é linearmente separável pelos descritores utilizados.

A análise de coeficientes (Figura 7(e)) revela uma discrepância crítica entre expectativa física e realidade estatística: elementos químicos nos sítios i e/ou j apresentam coeficientes de maior magnitude absoluta, sugerindo predominância da identidade química do ligante. Contudo, a variável distância, que fisicamente deveria dominar V dado o caráter do tipo Coulomb com decaimento radial, apresenta coeficiente baixo (-0.004). Esta inversão de importância evidencia que a dependência exponencial de V com a distância, observada na análise exploratória, não é compreendida pelo modelo linear utilizado aqui. O conjunto de resultados obtidos, como o baixo R^2 na base de treino e teste, não-normalidade dos resíduos e baixa importância da distância no modelo, motiva a transição para técnicas não-lineares, cujos resultados são explorados na seção seguinte.

Floresta Aleatória para prever V

Em contraste com o modelo linear, a Floresta Aleatória apresenta capacidade preditiva expressiva, com R^2 de 0.782 e RMSE de 0.050 eV na base teste, demonstrando que a relação entre V e os descritores disponíveis é de natureza não linear e pode ser capturada por modelos baseados em árvore (Tabela 7). A baixa diferença entre as métricas de treino e teste (R^2 de 0.882 e 0.782, respectivamente) indica a presença de uma boa generalização do modelo sem *overfitting* significativo.


Tabela 7. Métricas R^2 , RMSE e MAE, analisadas na base de treino e teste, para o modelo de floresta aleatória para o subconjunto V

	Treino	Teste
R^2	0.882	0.782
RMSE	0.053	0.050
MAE	0.025	0.026

Fonte: Resultados originais da pesquisa

A concentração de pontos ao longo da diagonal para os valores preditos versus os valores reais, na Figura 8(a), evidenciada pela alta densidade na região central do gráfico, indica boa aderência do modelo para a faixa mais representada de V (próxima a zero). Entretanto, observa-se ainda a existência de diversos pontos *outliers* distantes da diagonal. É

O histograma de resíduos (Figura 8(b)) apresenta uma aderência a normalidade levemente superior ao modelo linear, com uma menor assimetria, sendo que aqui, o teste de Shapiro-Francia também rejeita a hipótese de normalidade ($W = 0.631$; $p = 0$). A distribuição de resíduos (Figura 8(c)) confirma a melhora qualitativa: os resíduos distribuem-se predominantemente em torno de zero, com menos resíduos positivos e consequentemente uma menor subestimação nas predições. O agrupamento por elemento químico nas Figuras 8(a) e 8(c) é menos pronunciado que no modelo linear, indicando que a Floresta Aleatória captura melhor a variabilidade de V , reduzindo a dependência da predição exclusivamente da identidade química do par de átomos.



Fonte: Resultados originais da pesquisa

19

linear, é particularmente significativa e com interpretação física. Este padrão de importância contrasta com U, onde a identidade do átomo i domina amplamente, reforçando que V é determinado pela geometria e natureza química do par de sítios, enquanto U é uma propriedade essencialmente local.

Apesar da melhora expressiva em relação ao modelo linear, o desempenho da Floresta Aleatória ainda apresenta margem para melhora. O R^2 de 0.782 na base de teste indica que aproximadamente 22% da variabilidade de V permanece inexplicada, e a dispersão crescente para valores extremos sugere que interações atípicas e distantes de zero ainda não são completamente capturadas.

Comparação com a literatura

Os resultados obtidos neste trabalho revelam uma distinção fundamental para a predição dos parâmetros intra-sítio U e inter-sítio V, onde U é uma propriedade essencialmente local, determinada pela identidade química do átomo e sua estrutura eletrônica, enquanto V depende da geometria do par de sítios e decai com a distância, introduzindo não linearidades que modelos aditivos não capturam adequadamente. Esta observação alinha-se com o trabalho de Uhrin *et al.* que reportaram que a transferibilidade de U entre diferentes ambientes químicos é significativamente maior que a de V, justamente devido ao caráter mais local do primeiro, utilizando redes neurais equivariantes (Uhrin *et al.*, 2025). Os autores obtiveram erro absoluto relativo médio de apenas 3% para U versus 5% para V, corroborando a maior "previsibilidade" de parâmetros intra-sítio.

O modelo de regressão linear múltipla treinado para U apresenta uma MAE de 0.181 eV que é competitiva com outros resultados apresentados na literatura, considerando a diversidade química do banco de dados utilizado (TBHubbard). Cai *et al.* (2024) aplicam a Floresta Aleatória para sistemas do tipo Mn-O, reportando uma MAE de 0.128 eV (Cai *et al.*, 2024). Xia *et al.* (2024) utilizou um Bagging Regressor com XGBoost para sistemas do tipo Fe-O, reportando uma MAE de aproximadamente 0.45 eV. Esta comparação evidencia que modelos focados em sistemas com elementos químicos específicos tendem a apresentar maior precisão absoluta, enquanto incorporar múltiplos elementos simultaneamente (Cu, Ni, Zr, Hf, O, N, entre outros), pode reduzir a acurácia, mas apresentar uma maior generalidade, como é o caso do modelo desenvolvido aqui.

Uma divergência notável com outros trabalhos é a importância do volume do material (22%) para o subconjunto V na Floresta Aleatória, descritor estrutural que não aparece como central em estudos de sistemas cristalinos simples (Cai *et al.*, 2024; Xia *et al.*, 2024). Esta discrepância talvez reflita a natureza porosa dos MOFs, onde em materiais com alta

densidade de poros, o volume unitário está correlacionado com a densidade de átomos e, consequentemente, com a intensidade média das interações inter-sítio. Isto pode indicar que descritores relevantes para V são sensíveis à classe de materiais estudada, sendo necessária cautela na transferência de modelos entre classes de materiais distintas.

A predição do parâmetro V permanece escassamente explorada na literatura, reflexo da limitada disponibilidade de bases de dados com valores calculados de forma auto-consistente. Esta escassez ressalta a relevância do banco TBHubbard como recurso para treinamento de modelos preditivos. Neste contexto, estabelecemos comparação direta com Carvalho *et al.* (2025), observando que ambos os trabalhos compartilham o mesmo banco de dados, mas adotam estratégias metodológicas distintas na definição de descritores (Costa Carvalho *et al.*, 2025; Costa Carvalho; Zipoli, 2025).

Enquanto o presente estudo utiliza descritores estruturais acessíveis, como volume, densidade, dimensões de poros e identidade química dos átomos, Carvalho *et al.* (2025) empregam representações matriciais da estrutura eletrônica via parâmetros do tipo *tight-binding* (Costa Carvalho *et al.*, 2025). No entanto, enquanto tais matrizes incorporam informações físicas mais complexas ao modelo, sua obtenção demanda cálculos eletrônicos específicos que não necessariamente estão imediatamente disponíveis para materiais fora do banco de dados. Em contrapartida, os descritores estruturais aqui utilizados podem ser extraídos diretamente de geometrias cristalinas, viabilizando o uso do modelo para materiais fora do banco de dados.

Apesar das diferenças metodológicas, as métricas de desempenho apresentam um bom acordo, em que Carvalho *et al.* (2025) reportam R^2 médio na validação cruzada de 0.914 e MAE de 0.134 eV para predição simultânea de U e V via Floresta Aleatória com matrizes do tipo “tight-binding”. Comparando com os valores obtidos aqui (R^2 de 0.782 e MAE de 0.050 eV) para V isoladamente, o melhor desempenho do modelo de Carvalho *et al.* (2025) pode ser atribuído de forma qualitativa à maior complexidade dos descritores do tipo “tight-binding”, embora o MAE do presente trabalho seja substancialmente menor, influenciado pela menor magnitude de V em comparação a U . A proximidade dos resultados sugere que informações estruturais elementares utilizadas aqui são suficientes para capturar minimamente a variabilidade dominante de V , sendo que representações “tight-binding” podem ser mais determinantes para refinar a precisão do modelo.

Limitações e próximos passos

Aqui, a distribuição desigual de observações por elemento químico é uma das maiores limitações dos modelos treinados aqui com o banco de dados TBHubbard. Tal condição

também é mencionada em outros trabalhos como fator limitante (Cai *et al.*, 2024; Xia *et al.*, 2024). Como o elemento químico é uma variável descritora importante para os subconjuntos U e V, é importante que existam abundância e diversidade no banco de dados de treinamento para o modelo ser generalizável. Além do desbalanceamento químico, outros aspectos restringem a aplicabilidade dos resultados: (i) a exclusão da variável *lcd* é justificada pelo ponto de corte definido aqui para o VIF, porém esta decisão poder ser considerada arbitrária, removendo uma variável que pode ser potencialmente relevante em outros contextos; (ii) os modelos ajustados utilizam apenas variáveis estruturais e de identidade química, sem capturar o ambiente local das interações; e (iii) a base TBHubbard conta com apenas 242 estruturas e apenas uma classe de materiais (MOFs), o que restringe o potencial de transferibilidade para tipos de materiais não incluídos no treinamento. Isso evidencia o papel relevante do TBHubbard e estimula a expansão do banco de dados, com maior variedade de elementos químicos e classes de materiais.

Como perspectivas futuras, a incorporação de variáveis mais sofisticadas e que tragam mais informação física sobre o material, pode melhorar substancialmente o desempenho dos modelos. Em particular, Redes Neurais de Grafos (GNNs) representam arquitetura promissora para este problema (Reiser *et al.*, 2022; Scarselli *et al.*, 2009). As GNNs operam diretamente sobre a estrutura cristalina como grafo, onde os nós representam átomos e arestas representam ligações ou interações, permitindo capturar relações de vizinhança e simetrias de forma natural. Para V, as GNNs oferecem vantagem especial com a capacidade de aprender a geometria local do par atômico, incluindo informações sobre a coordenação dos sítios atômicos (quem são seus vizinhos e com quem eles estão ligados).

Considerações Finais

Os resultados obtidos permitem concluir que U e V apresentam naturezas fundamentalmente distintas, o que demanda abordagens metodológicas diferentes.

Para o parâmetro intra-sítio U, o modelo de regressão linear múltipla com seleção stepwise demonstrou elevada capacidade preditiva, confirmando que U é essencialmente determinado pela identidade química do átomo no sítio *i*. As variáveis estruturais, apresentaram contribuição secundária, enquanto as variáveis de elemento químico dominaram os coeficientes do modelo. O modelo generaliza bem para elementos abundantes no banco de dados, como O, Zr e Hf, mas subestima a predição para elementos menos representados, como Cu e Br, limitação diretamente associada ao desbalanceamento do banco de dados.

Para o parâmetro inter-sítio V , o modelo linear mostrou-se inadequado e incapaz de capturar a dependência não-linear de V com a distância entre sítios e a natureza do par atômico. A transição para a Floresta Aleatória resultou em melhora expressiva no desempenho do modelo na base de teste, com a distância emergindo como variável relevante, o que confirma o caráter não-local de V e sua dependência geométrica. Ainda assim, aproximadamente 22% da variabilidade de V permanece inexplicada, indicando que descritores mais complexos do ambiente eletrônico local, como representações *tight-binding* ou a utilização de redes neurais de grafos, podem ser necessários para o refinamento de futuros modelos.

Em conjunto, os resultados demonstram que variáveis estruturais elementares e que são acessíveis diretamente de geometrias cristalinas são suficientes para prever U com precisão competitiva à literatura e para capturar a variabilidade dominante de V , sem necessidade de cálculos eletrônicos prévios. Os modelos desenvolvidos aqui oferecem uma alternativa de baixo custo computacional para a estimativa dos parâmetros de Hubbard diretamente a partir de geometrias cristalinas, ampliando o potencial de aplicação em design computacional de MOFs.

Agradecimento

Agradeço ao meu marido Leonardo Gomes pelo apoio durante o processo de escrita.

Agradeço ao meu orientador Walter Mesquita e a todos os professores do MBA USP Esalq pelo aprendizado.

Referências

Bavykina, A.; Kolobov, N.; Khan, I. S.; Bau, J. A.; Ramirez, A.; Gascon, J. 2020. Metal–Organic Frameworks in Heterogeneous Catalysis: Recent Progress, New Trends, and Future Perspectives. *Chemical Reviews*, v. 120, n. 16, p. 8468–8535. Disponível em: <https://doi.org/10.1021/acs.chemrev.9b00685>.

Belsley, D. A.; Kuh, E.; Welsch, R. E. 1980. *Regression Diagnostics*. [N.p.]: Wiley. Disponível em: <https://doi.org/10.1002/0471725153>.

Breiman, L. 2001. Random Forests. *Machine Learning*, v. 45, n. 1, p. 5–32. Disponível em: <https://doi.org/10.1023/A:1010933404324>.

Breiman, L.; Friedman, J. H.; Olshen, R. A.; Stone, C. J. 1984. *Classification and Regression Trees*. [N.p.]: Wadsworth International Group.

Cai, G.; Cao, Z.; Xie, F.; Jia, H.; Liu, W.; Wang, Y.; Liu, F.; Ren, X.; Meng, S.; Liu, M. 2024. Predicting structure-dependent Hubbard U parameters via machine learning. *Materials Futures*, v. 3, n. 2, p. 025601. Disponível em: <https://doi.org/10.1088/2752-5724/ad19e2>.

Costa Carvalho, P.; Zipoli, F. 2025. TBHubbard Dataset. Harvard Dataverse. Disponível em: <https://dataverse.harvard.edu/dataset.xhtml?persistentId=doi:10.7910/DVN/ZKLRLF>.

Costa Carvalho, P.; Zipoli, F.; Duriez, A. C.; Barroca, M. A.; Neumann Barros Ferreira, R.; Jones, B.; Wunsch, B.; Steiner, M. 2025. TBHubbard: tight-binding and extended Hubbard model dataset for metal-organic frameworks. *Scientific Data*, v. 12, n. 1, p. 1776. Disponível em: <https://doi.org/10.1038/s41597-025-06054-w>.

Fávero, L. P.; Belfiore, P. 2024. Manual de análise de dados: estatística e machine learning com Excel®, SPSS®, Stata®, R® e Python®. [N.p.]: GEN/LTC.

Gujarati, D.; Porter, D. C. 2011. *Econometria Básica*. [N.p.]: AMGH/Bookman.

Hair, J. F.; Black, W. C.; Babin, B. J.; Anderson, R. E. 2019. *Multivariate Data Analysis*. [N.p.]: Cengage.

Hocking, R. R.; Pendleton, O. J. 1983. The regression dilemma. *Communications in Statistics - Theory and Methods*, v. 12, n. 5, p. 497–527. Disponível em: <https://doi.org/10.1080/03610928308828477>.

Hohenberg, P.; Kohn, W. 1964. Inhomogeneous Electron Gas. *Physical Review*, v. 136, n. 3B, p. B864–B871. Disponível em: <https://link.aps.org/doi/10.1103/PhysRev.136.B864>.

James, G.; Witten, D.; Hastie, T.; Tibshirani, R. 2021. *An Introduction to Statistical Learning*. New York, NY: Springer US. Disponível em: <https://doi.org/10.1007/978-1-0716-1418-1>.

Kohn, W.; Sham, L. J. 1965. Self-Consistent Equations Including Exchange and Correlation Effects. *Physical Review*, v. 140, n. 4A, p. A1133–A1138. Disponível em: <https://link.aps.org/doi/10.1103/PhysRev.140.A1133>.

Kutner, M. H.; Nachtsheim, C. J.; Neter, J.; Li, W. 2004. *Applied Linear Regression Models*. [N.p.]: McGraw-Hill.

Leiria Campo Jr., V.; Cococcioni, M. 2010. Extended DFT + U + V method with on-site and inter-site electronic interactions. *Journal of Physics: Condensed Matter*, v. 22, n. 5, p. 055602. Disponível em: <https://doi.org/10.1088/0953-8984/22/5/055602>.

Mancuso, J. L.; Mroz, A. M.; Le, K. N.; Hendon, C. H. 2020. Electronic Structure Modeling of Metal–Organic Frameworks. *Chemical Reviews*, v. 120, n. 16, p. 8641–8715. Disponível em: <https://doi.org/10.1021/acs.chemrev.0c00148>.

Pavarini, E. 2021. Solving the strong-correlation problem in materials. *La Rivista del Nuovo Cimento*, v. 44, n. 11, p. 597–640. Disponível em: <https://doi.org/10.1007/s40766-021-00025-8>.

Reiser, P.; Neubert, M.; Eberhard, A.; Torresi, L.; Zhou, C.; Shao, C.; Metni, H.; Van Hoesel, C.; Schopmans, H.; Sommer, T.; Friederich, P. 2022. Graph neural networks for materials science and chemistry. *Communications Materials*, v. 3, n. 1, p. 93. Disponível em: <https://doi.org/10.1038/s43246-022-00315-6>.

Rosen, A. S.; Fung, V.; Huck, P.; O'Donnell, C. T.; Horton, M. K.; Truhlar, D. G.; Persson, K. A.; Notestein, J. M.; Snurr, R. Q. 2022. High-throughput predictions of metal–organic framework electronic properties: theoretical challenges, graph neural networks, and data

exploration. *npj Computational Materials*, v. 8, n. 1, p. 112. Disponível em: <https://doi.org/10.1038/s41524-022-00796-6>.

Rosen, A. S.; Iyer, S. M.; Ray, D.; Yao, Z.; Aspuru-Guzik, A.; Gagliardi, L.; Notestein, J. M.; Snurr, R. Q. 2021. Machine learning the quantum-chemical properties of metal–organic frameworks for accelerated materials discovery. *Matter*, v. 4, n. 5, p. 1578–1597. Disponível em: <https://doi.org/10.1016/j.matt.2021.02.015>.

Scarselli, F.; Gori, M.; Tsoi, A. C.; Hagenbuchner, M.; Monfardini, G. 2009. The Graph Neural Network Model. *IEEE Transactions on Neural Networks*, v. 20, n. 1, p. 61–80. Disponível em: <https://doi.org/10.1109/TNN.2008.2005605>.

Shapiro, S. S.; Francia, R. S. 1972. An Approximate Analysis of Variance Test for Normality. *Journal of the American Statistical Association*, v. 67, n. 337, p. 215–216. Disponível em: <https://doi.org/10.1080/01621459.1972.10481232>.

Tukey, J. W. 1977. *Exploratory Data Analysis*. [N.p.]: Addison-Wesley Publishing Company.

Uhrin, M.; Zadoks, A.; Binci, L.; Marzari, N.; Timrov, I. 2025. Machine learning Hubbard parameters with equivariant neural networks. *npj Computational Materials*, v. 11, n. 1, p. 19. Disponível em: <https://doi.org/10.1038/s41524-024-01501-5>.

Wu, Z.; Yi, Y.; Hai, F.; Tian, X.; Zheng, S.; Guo, J.; Tang, W.; Hua, W.; Li, M. 2023. A Metal–Organic Framework Based Quasi-Solid-State Electrolyte Enabling Continuous Ion Transport for High-Safety and High-Energy-Density Lithium Metal Batteries. *ACS Applied Materials & Interfaces*, v. 15, n. 18, p. 22065–22074. Disponível em: <https://doi.org/10.1021/acsami.3c00988>.

Xia, W.; Chen, G.; Zhu, Y.; Hou, Z.; Tsuchiya, T.; Wang, X. 2024. Machine Learning Model for the Prediction of Hubbard U Parameters and Its Application to Fe–O Systems. *Journal of Chemical Theory and Computation*, v. 20, n. 22, p. 10095–10102. Disponível em: <https://doi.org/10.1021/acs.jctc.4c01004>.

Zhao, H.; Dong, J.; Chen, S.; Wang, H.; Zhao, G. 2024. Metal-organic frameworks and their composites for carbon dioxide capture: Recent advances and challenges. *Fuel*, v. 378, p. 132973. Disponível em: <https://doi.org/10.1016/j.fuel.2024.132973>.

